



Analyse et Modélisation des Dyskinésies : Approches Optogénétiques et Apprentissage Automatique

Octobre 2024 - Janvier 2025

Rapport de la classe Robotique de l'ENSEIRB Matmeca et
ENSC

Bonnet, Cattarin, Clement, Ezzagmouny, Gouhey, Hamouche,
Hauswald, Humbertclaude, Lauga, Pierson, Reinert, Rodriguez
et Vernant

Contents

1	Organisation et Intégration	2
1.1	Organisation du Travail	2
2	Étudier une alternative possible	4
2.1	MMLab	4
2.2	SLEAP	4
2.3	Comparaison des technologies	4
3	Utilisation avancée : DLC et BSoid	6
3.1	DeepLabCut	6
3.2	B-SOiD	7
4	Pistes pour extraire des événements importants	8
4.1	Identification des critères de sélection	8
4.2	Utilisation des outils de détection automatisée	8
4.3	Segmentation et annotation des séquences	8
4.4	Intégration des mécanismes d'attention et des Transformers	8
5	Meilleures stratégies pour minimiser le temps d'étiquetage	10
5.1	L'étiquetage au sein du projet	10
5.2	Outils pour l'étiquetage	10
5.2.1	Définitions et comparaisons	11
5.2.2	Étiquetage de comportements	11

1 Organisation et Intégration

Les dyskinésies sont des mouvements involontaires que les patients souffrant de la maladie de Parkinson peuvent avoir. L'étude de ces mouvements repose, d'une part, sur des mécanismes neuronaux qu'il convient de mieux comprendre, et d'autre part, sur des analyses précises de comportements moteurs. Pour cela, il est crucial ici de recourir à des outils technologiques performant comme les systèmes d'apprentissage automatique pour la machine et les logiciels d'analyse (comportementale) automatisée.

Ce projet s'intéresse à de tels mécanismes à travers une articulation de ces approches avec des techniques d'analyses automatiques du comportement. Différents outils tels que DeepLabCut (DLC), B-SOID, et la suite MMLab (MMPose) seront inspectés, analysés et comparés afin d'évaluer les meilleures options pouvant être utilisées pour analyser les comportements dyskinétiques.

L'articulation entre les membres du groupe permettra de structurer le projet de manière à ce que chacun s'approprie son axe de recherche, bien différencié des autres, tout en prenant en compte les liens possibles entre chacun de ces axes.

1.1 Organisation du Travail

Afin d'assurer une progression fluide et une couverture complète des objectifs du projet, le travail a été réparti en plusieurs sous-groupes, chacun chargé d'une tâche spécifique :

- **Organisation et intégration**

Responsable : Charlène

Ce groupe est chargé de coordonner l'ensemble du projet, d'assurer une communication efficace entre les membres et de veiller à l'intégration harmonieuse des différentes sections du rapport final.

- **Étudier une alternative possible (suite MMLab ou autre)**

Responsables : Mathis, Bouchra et Esteban R.

Ce groupe explore des alternatives à MMLab, notamment des outils comme SLEAP, afin d'évaluer leur pertinence et les performances pour l'analyse comportementale.

- **Utilisation avancée (et documentée) de DLC, B-SOID et autre**

Responsables : Arthur, Louis et Esteban G.

L'objectif est de maîtriser et documenter l'utilisation avancée des outils existants afin d'extraire les informations comportementales avec précision.

- **Pistes pour extraire des événements importants**

Responsables : Luxel, Antton et Tom

Ce groupe se concentre sur l'identification et l'extraction d'événements comportementaux clés, en se basant sur les données collectées par les autres groupes.

- **Meilleures stratégies pour minimiser le temps d'étiquetage**

Responsables : Kloé, Guillaume et Adrien

L'objectif est de développer des stratégies efficaces pour réduire le temps d'étiquetage manuel, tout en garantissant une haute qualité des annotations.

La tâche de chaque groupe consistera à élaborer une analyse approfondie et structurée de son sujet, des résultats concrets, ainsi qu'une documentation explicite. Un contact régulier entre les groupes garantira à la fois une bonne cohérence du projet et un bon partage des résultats dans le rapport final.

Ce document constituera le cadre de travail garantissant l'organisation des différentes étapes du projet et le respect des délais.

2 Étudier une alternative possible

Les dyskinésies, qui se retrouvent essentiellement en lien avec la maladie de Parkinson, sont des mouvements involontaires pouvant être invalidants, ce qui rend nécessaire de bien comprendre les mécanismes neuronaux à l'origine de ces mouvements. L'analyse fine des comportements moteurs est un prérequis et nécessite des outils spécifiques.

Si plusieurs outils existent déjà en ce sens, il existe des limites sur les plans techniques ou méthodologiques, ce qui incite à explorer des solutions alternatives. Cette section se concentre dès lors sur l'étude de MMLab (MMPose) et d'outils similaires. Il est nécessaire d'en estimer le potentiel, la performance, mais aussi l'adaptabilité à l'étude des dyskinésies.

L'objectif vise ici à établir une analyse comparative éclairée et à émettre des recommandations en vue d'opter éventuellement, et plus adéquatement, pour une technologie mieux appropriée aux besoins du projet.

2.1 MMLab

MMLab est une suite logicielle open-source développée pour les algorithmes de vision par ordinateur par apprentissage. Plusieurs outils ont été conçus pour analyser et interpréter des données visuelles complexes, avec des performances intéressantes.

MMPose est un outil d'estimation de pose des humains et des animaux, bénéficiant d'une bibliothèque de modèles pré-entraînée, et d'une architecture modulaire qui permet un bon degré de flexibilité en fonction des besoins des utilisateurs.

Cet outil permet la détection d'informations sur les positions corporelles et s'adapte à des comportements au fil du temps. Il est possible de reconnaître, a priori, des "réurrences" dans des schémas comportementaux. Cet outil pourrait donc être crucial pour automatiser l'analyse comportementale de modèles animaux, tels que le suivi des mouvements, tout en réduisant l'intervention humaine nécessaire dans cette analyse.

2.2 SLEAP

Nous allons nous intéresser à une alternative à MMLab nommée SLEAP (Social LEAP Estimates Animal Poses), pour la mise au point de l'analyse comportementale. C'est un logiciel libre dédié à l'analyse comportementale animale à partir de vidéos.

SLEAP est spécifiquement conçu pour le domaine des neurosciences comportementales. Son but est de suivre et d'analyser le mouvement des animaux, mais aussi les interactions entre plusieurs individus, par le biais de techniques d'apprentissage profond (*deep learning*).

Des atouts importants sont, par exemple, sa capacité à suivre plusieurs individus à la fois, sa conception à interface intuitive pour réaliser l'annotation et l'entraînement des modèles, ou encore la possibilité de personnalisation des paramètres pour chaque expérience et chaque besoin. [pereira2022sleap]

2.3 Comparaison des technologies

MMLab (MMPose) et SLEAP sont deux outils open-source spécialisés dans l'analyse comportementale animale et l'estimation de pose. Ils partagent plusieurs objectifs communs, mais se distinguent par

leurs approches et leurs fonctionnalités.

En ce qui concerne la précision, les performances sont globalement satisfaisantes, mais SLEAP est plus performant dans des scènes compliquées, riches et variées. Concernant le suivi multi-animal, MMLab sait suivre plusieurs animaux, mais serait plus complexe à mettre en œuvre. SLEAP est fait pour ce genre de suivi, intuitivement et robustement.

En termes de facilité d'utilisation, MMLab s'appuie sur une interaction en ligne de commande à prendre en main. SLEAP propose une interface graphique plus adaptée, facilitant les tâches d'annotations, de traitement et de contrôle des vidéos. En matière de personnalisation, MMLab offre mécaniquement plus de choix pour calibrer et paramétrer les modèles d'estimation de pose et de mouvements.

Les besoins en ressources matériels des deux projets sont conséquents, notamment pour le traitement de vidéos complexes, aucun des deux outils n'ayant d'avantages en ce sens face à l'autre. Enfin, MMLab dispose d'une communauté et d'une documentation plus fournies, et donc plus accessibles et, en théorie, plus riches d'informations d'apprentissage et de soutien, en opposition à SLEAP dont la communauté active reste plus rare.

Le tableau suivant permet d'identifier rapidement et efficacement toutes ces différences.

Critères	MMLab (MMPose)	SLEAP	Avantage
Précision	Élevée	Très élevée	SLEAP
Suivi multi-animal	Possible	Optimisé	SLEAP
Facilité d'utilisation	Complexe	Intuitif	SLEAP
Personnalisation	Très flexible	Flexible	MMLab
Ressources matérielles	Importantes	Importantes	Égalité
Communauté	Étendue	Petite	MMLab

Table 1: Comparaison entre MMLab (MMPose) et SLEAP

3 Utilisation avancée : DLC et BSoiD

L'analyse des comportements moteurs dyskinétiques nécessite des outils performants capables de capturer et d'interpréter des mouvements complexes. Parmi ces outils, DeepLabCut (DLC) et B-SOiD se distinguent par leur capacité à fournir des analyses précises et automatisées. En combinant ces technologies, il devient possible d'obtenir une compréhension approfondie des comportements pathologiques.

3.1 DeepLabCut

DeepLabCut est un logiciel libre de suivi de pose basé sur des réseaux de neurones convolutifs. Il permet de suivre avec précision les mouvements d'êtres vivants à partir de vidéos. Son approche non intrusive est particulièrement adaptée aux études comportementales, car elle réduit les biais expérimentaux liés à la présence de capteurs. DLC est largement utilisé dans les neurosciences comportementales pour analyser des mouvements complexes de manière détaillée.

DLC nécessite d'être entraîné sur un dataset annoté avec les points d'intérêt. Ces données annotées sont ensuite utilisées pour entraîner un modèle de réseau neuronal basé sur ResNet, qui apprend à reconnaître et prédire la position de ces points clés sur de nouvelles images. Une fois le modèle entraîné, il peut être appliqué à des vidéos entières pour fournir des trajectoires précises des mouvements analysés. DLC prend en charge différentes architectures et permet une personnalisation fine des modèles en fonction des besoins spécifiques de l'étude.

Dans le cadre de ce projet sur les dyskinésies, DLC est un outil clé pour analyser les mouvements involontaires des patients atteints de la maladie de Parkinson. Sa capacité à capturer des comportements moteurs permet d'identifier des schémas de mouvements anormaux avec une grande précision. De plus, l'absence de marqueurs physiques assure que les comportements observés sont naturels, ce qui est essentiel pour une analyse fiable. En combinant DLC avec des outils complémentaires, il est possible de quantifier objectivement les manifestations dyskinétiques et d'évaluer l'effet de traitements potentiels.

La documentation de DeepLabCut est disponible sur GitHub [17]. Il est possible d'y trouver un rapide tutoriel qui indique ce qu'il faut installer pour pouvoir utiliser DeepLabCut, c'est-à-dire, les dépendances:

- Python 3.10+,
- TensorFlow v2.10,

La documentation sur GitHub donne aussi accès à des fichiers d'exemples Jupyter Notebook pour apprendre à utiliser les différentes fonctionnalités de l'outil. Les deux principaux étant un fichier pour faire du suivi de poses pour un seul animal [6] et un autre pour faire du suivi de poses pour plusieurs animaux [5].

Il est indiqué sur le premier Notebook comment :

- charger des données,
- créer un set d'entraînement,
- entraîner un réseau de neurones,
- évaluer un réseau de neurones,

- analyser une vidéo.

Afin de pouvoir réaliser les entraînements de réseau de neurones du tutoriel de manière rapide, il est nécessaire de posséder une puissance de calcul suffisante.

Pour cela, il est possible de réaliser les calculs directement sur Google Collab afin de déporter les calculs sur les serveurs de Google offrant des calculs déportés sur GPU plus ou moins puissants en fonction du type d'abonnement.

Il est également possible de lancer les calculs en local sur sa machine. Dans ce cas, il est recommandé de posséder un GPU sous architecture NVIDIA afin de pouvoir utiliser l'interface CUDA. Il est possible également d'effectuer les calculs en local sur sa machine avec des GPU sous architectures AMD ou Intel. Il faudra cependant posséder un OS Windows 10 ou 11 et effectuer une installation différente, plus complexe et plus susceptible de ne pas fonctionner [7].

3.2 B-SOiD

B-SOiD (Behavioral Segmentation of Open-field in DeepLabCut) est un logiciel libre qui automatise la segmentation et la classification des comportements à partir des données de suivi générées par des outils comme DeepLabCut. Il utilise des techniques d'apprentissage non supervisé pour identifier des motifs comportementaux récurrents.

Le fonctionnement de B-SOiD repose sur la transformation des données de suivi de pose en caractéristiques exploitables par des algorithmes d'apprentissage non supervisé. Une fois les données de DLC importées, B-SOiD applique des techniques de réduction de dimensionnalité, comme t-SNE, pour visualiser les données comportementales, puis utilise des algorithmes de regroupement (*clustering*) pour associer les comportements similaires. Chaque groupe représente un type de comportement distinct, identifié sans intervention humaine, permettant une segmentation automatique des séquences vidéos.

B-SOiD est particulièrement utile pour ce projet car il permet d'automatiser l'identification de comportements moteurs complexes et récurrents en utilisant les résultats produits par DLC. Ainsi, l'association de B-SOiD avec DeepLabCut enrichit l'analyse comportementale en combinant la précision du suivi de pose avec la segmentation automatique des comportements. Cela offre une compréhension plus complète des mouvements étudiés.

La documentation sur GitHub [15] contient un guide d'installation qui indique les principales étapes à respecter sur Linux, MacOS ou Windows.

Enfin, dans le dossier de documentation du dépôt se trouvent les différents tutoriels des fonctionnalités de B-SOiD pour différents langages comme python ou matlab.

4 Pistes pour extraire des événements importants

L'extraction des événements importants constitue une étape clé dans l'analyse des données comportementales, notamment dans le contexte des dyskinésies associées à la maladie de Parkinson. Cette partie propose des approches permettant d'identifier ces événements de manière précise et efficace.

4.1 Identification des critères de sélection

Pour extraire ces événements importants, il est nécessaire de définir des critères de sélection pertinents. Ces critères peuvent inclure, par exemple, des variations rapides de trajectoires ou de positions, des fréquences ou amplitudes spécifiques de mouvements indicateurs de dyskinésies, ou des transitions entre comportements distincts.

Ces critères devront être validés en consultation avec des experts en neurosciences et en analyse comportementale.

4.2 Utilisation des outils de détection automatisée

Plusieurs outils permettent d'identifier automatiquement des événements significatifs dans les données. Par exemple, DeepLabCut et MMPose offrent des solutions avancées pour suivre les mouvements, ce qui est particulièrement utile pour repérer des anomalies comportementales ou des gestes répétitifs liés aux dyskinésies. B-SOID et SLEAP utilisent des techniques d'apprentissage automatique pour analyser les comportements et détecter des schémas spécifiques.

L'analyse spectrale pourrait aussi permettre d'examiner la fréquence des mouvements afin d'identifier des phénomènes périodiques, comme des tremblements qui sont caractéristiques des dyskinésies. En combinant ces outils, on peut exploiter leurs points forts respectifs et obtenir des analyses plus fiables et précises.

4.3 Segmentation et annotation des séquences

Pour approfondir l'analyse des données, il est important de les segmenter en séquences correspondant à des comportements spécifiques. Cette segmentation peut être réalisée de manière semi-automatique en s'appuyant sur différentes approches. Parmi celles-ci figurent les algorithmes de détection des points de rupture dans les données temporelles, les méthodes d'apprentissage supervisé permettant d'identifier des comportements récurrents, ainsi que des approches de segmentation automatique non supervisée. Ces dernières incluent des outils tels que MoSeq2, qui utilisent des techniques avancées de modélisation probabiliste pour segmenter et identifier les motifs comportementaux sans nécessiter d'annotations préalables.

4.4 Intégration des mécanismes d'attention et des Transformers

Les mécanismes d'*Attention* et les architectures *Transformer* [21] représentent des approches modernes particulièrement adaptées à l'analyse de séquences complexes. Ces outils offrent plusieurs avantages, notamment la priorisation des informations importantes, centrale dans cette partie. En effet, les mécanismes d'attention permettent de focaliser l'analyse sur des moments clés, en réduisant l'impact des données non pertinentes. De plus, les *Transformers* peuvent détecter des motifs comportementaux

complexes qui ne sont pas nécessairement consécutifs dans les données grâce à leur capacité à modéliser les dépendances à longue portée. D'autres modèles tels que les *Vision Transformers* (ViT) [8] pourraient être utilisés pour identifier des mouvements caractéristiques des dyskinésies.

Malgré leurs avantages, ces méthodes nécessitent des ressources computationnelles significatives et une quantité importante de données annotées pour un entraînement efficace. Leur intégration dans les futures approches pourrait cependant offrir des performances supérieures pour l'extraction des événements rares ou complexes.

5 Meilleures stratégies pour minimiser le temps d'étiquetage

Dans cette dernière partie, il s'agit d'identifier et d'explorer les outils et stratégies permettant de minimiser le temps nécessaire à l'étiquetage des vidéos. En effet, l'étiquetage manuel étant une tâche particulièrement chronophage, l'adoption d'outils automatisés constitue une solution efficace pour optimiser ce processus.

5.1 L'étiquetage au sein du projet

L'étiquetage dans ce cas d'étude se fait sur des vidéos mais il est aussi possible d'en réaliser sur d'autres types de flux de données. De plus, bien que les vidéos d'animaux en action soient généralement capturées depuis un seul point de vue à l'aide de caméras vidéo standards, des innovations récentes, telles que les caméras de profondeur et les techniques de fusion d'images, permettent désormais de suivre les mouvements d'animaux en liberté en 3D [4].

Les souris sont séparées en trois catégories selon leur pathologie :

- **Normal** : Activité locomotrice standard sans anomalies détectables.
- **Parkinson** : Ralentissement des mouvements, rigidité, ou comportements moteurs caractéristiques de la maladie de Parkinson.
- **Dyskinésie** : Mouvements involontaires, souvent rapides et erratiques, induits par des conditions spécifiques ou des traitements.

Pour cela, il faut donc non seulement étiqueter les pathologies mais aussi prendre en compte les comportements de la souris. Plusieurs travaux précédents présentent des étiquetages sur les comportements des souris [4, 3, 16, 23, 18, 10]. Les étiquetages réalisés portent sur le déplacement du rongeur comme marcher ou se tourner mais aussi d'autres actions courtes comme renifler, se gratter ou manger. Enfin, des comportements avec d'autres souris comme attaquer ou se rapprocher sont aussi étudiés. Par ailleurs, ces étiquettes peuvent être combinées comme "marcher" et "renifler" en même temps [4].

5.2 Outils pour l'étiquetage

L'étiquetage, ou plus généralement la classification de données, a longtemps été réalisé à la main. Cependant, ce type d'approche prend du temps. Des solutions algorithmiques, notamment celles utilisant l'Intelligence Artificielle, sont beaucoup plus considérées pour accélérer voire améliorer la classification.

Il existe deux grandes familles de méthodes de classification par intelligence artificielle : **l'apprentissage supervisé** et **l'apprentissage non supervisé**.

5.2.1 Définitions et comparaisons

L'apprentissage supervisé consiste en une première étape d'apprentissage de l'IA avec des données pré-classifiées. Une évaluation permet ensuite de mesurer la performance du modèle avant son utilisation sur des données externes à classer. Ce type d'apprentissage demande un temps et un investissement important, notamment car l'étiquetage des données se fait manuellement. Cependant, il permet un étiquetage plus fiable, en particulier pour des données complexes.

L'apprentissage non-supervisé, en revanche, analyse des données brutes pour en identifier les similitudes selon certains critères. Ainsi, le modèle identifie et associe des données dans des catégories. Ce type d'apprentissage est donc plus rapide à mettre en place mais n'est efficace que dans les cas où les similitudes et différences sont suffisamment distinguées. Ce type d'apprentissage ne nécessite cependant pas l'intervention humaine pour classer. L'IA peut être plus à même de qualifier certaines données difficiles à traiter pour un humain.

Dans notre cas, un apprentissage non supervisé sur les images ne permettra pas d'étudier et de distinguer certains mouvements complexes de la souris comme renifler ou être immobile car ces mouvements ne se distinguent pas assez pour être correctement identifiés. Cependant, un apprentissage supervisé prendra du temps, et ce, même si des portions de vidéos pouvaient être étiquetées en même temps. Ainsi, dans un projet à long terme, un apprentissage supervisé permettra une fiabilité plus importante de l'étiquetage, mais il est aussi possible d'envisager un apprentissage non supervisé pour un étiquetage rapide.

5.2.2 Étiquetage de comportements

Chacun des apprentissages vus précédemment propose diverses approches pour l'étiquetage de comportements notamment grâce à leurs propres méthodes, outils et plateformes.

D'abord, **l'apprentissage supervisé** et ses méthodes sont souvent utilisées lorsque l'anatomie étudiée est complexe [4].

- Il existe des plateformes permettant de créer des classifications de comportements basés sur des exemples annotés comme **CADABRA** [19] ou **JAABA** [14].
- De même, la plateforme **LocoMouse** utilise des techniques d'apprentissage automatique supervisé pour reconnaître la position précise des pattes, des articulations, du museau et de la queue chez les souris marchant sur une piste [16].
- **DeepEthogram** [3], un logiciel s'appuyant sur des réseaux neuronaux convolutionnels (CNN) pour convertir les pixels vidéo bruts en un éthogramme, c'est à dire une matrice indiquant la présence ou l'absence de comportements définis pour chaque image vidéo.
- **SimBA** (Simple Behavioral Analysis) est une boîte à outils open source pour la classification informatique des comportements sociaux complexes chez les animaux de laboratoire [9].
- **MARS** est un pipeline Python pour l'estimation de pose et la classification des comportements sociaux chez les souris en interaction, formé sur 15 000 images annotées pour la pose et 14 heures de vidéos pour des comportements sociaux spécifiques [20].

Des approches algorithmiques « non supervisées » peuvent extraire des caractéristiques reconnaissables par un humain et peuvent également produire des caractéristiques qu'un humain aurait du mal à nommer [4].

- Le séquençage de mouvements avec **MoSeq** est une méthode d'apprentissage non supervisée qui décompose le comportement de la souris en motifs réutilisables de moins d'une seconde, appelés syllabes. Cette approche permet de découvrir les syllabes et leur grammaire spécifique à une expérience [22, 23].
- Les analyses fréquentielles transforment les caractéristiques comportementales pour représenter les mouvements par leurs fréquences plutôt que par leur évolution temporelle. La plateforme **MotionMapper** applique cette approche pour formater les données vidéo avant l'identification des motifs comportementaux, ce qui est particulièrement adapté aux mouvements cycliques (marche, ...) et facilite l'identification de comportements similaires mais déphasés [2, 1].
- D'autres outils plus globaux avec un autoencodeur variationnel hiérarchique factorisé, capable d'apprendre des représentations désentrelacées et interprétables à partir de données séquentielles, sans supervision [12, 11].

L'étiquetage supervisé, bien que chronophage, apparaît comme la solution la plus fiable pour classifier les comportements complexes liés aux pathologies. Une approche hybride combinant étiquetage manuel initial et outils pourrait accélérer le processus. À terme, l'intégration de méthodes non supervisées permettrait de découvrir des motifs comportementaux subtils. Une évaluation comparative des outils disponibles sera essentielle pour choisir la stratégie la plus adaptée au projet.

References

- [1] Gordon J. Berman, William Bialek, and Joshua W. Shaevitz. “Predictability and hierarchy in *Drosophila* behavior”. In: *Proceedings of the National Academy of Sciences* 113.42 (Oct. 18, 2016). Publisher: Proceedings of the National Academy of Sciences, pp. 11943–11948. DOI: 10.1073/pnas.1607601113. URL: <https://www.pnas.org/doi/10.1073/pnas.1607601113> (visited on 01/11/2025).
- [2] Gordon J. Berman et al. “Mapping the stereotyped behaviour of freely moving fruit flies”. In: *Journal of The Royal Society Interface* 11.99 (Oct. 6, 2014). Publisher: Royal Society, p. 20140672. DOI: 10.1098/rsif.2014.0672. URL: <https://royalsocietypublishing.org/doi/10.1098/rsif.2014.0672> (visited on 01/11/2025).
- [3] James P Bohnslav et al. “DeepEthogram, a machine learning pipeline for supervised behavior classification from raw pixels”. In: *eLife* 10 (Sept. 2, 2021), e63377. ISSN: 2050-084X. DOI: 10.7554/eLife.63377. URL: <https://elifesciences.org/articles/63377> (visited on 01/05/2025).
- [4] Sandeep Robert Datta et al. “Computational Neuroethology: A Call to Action”. In: *Neuron* 104.1 (Oct. 2019), pp. 11–24. ISSN: 08966273. DOI: 10.1016/j.neuron.2019.09.038. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0896627319308414> (visited on 01/05/2025).
- [5] DeepLabCut Developers. *DeepLabCut Colab Demo: 3 Mice Tracking*. https://colab.research.google.com/github/DeepLabCut/DeepLabCut/blob/master/examples/COLAB/COLAB_3miceDemo.ipynb. (visited on 13/01/2025). 2025.
- [6] DeepLabCut Developers. *DeepLabCut Colab Demo: Mouse Open Field*. https://colab.research.google.com/github/DeepLabCut/DeepLabCut/blob/master/examples/COLAB/COLAB_DEMO_mouse_openfield.ipynb. (visited on 13/01/2025). 2025.
- [7] DeepLabCut Developers. *DeepLabCut: Installation Tips*. <https://deeplabcut.github.io/DeepLabCut/docs/recipes/installTips.html#installation-tips>. Accessed: 2025-01-13. 2025.
- [8] Alexey Dosovitskiy et al. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. 2021. arXiv: 2010.11929 [cs.CV]. URL: <https://arxiv.org/abs/2010.11929>.
- [9] Nastacia L. Goodwin et al. “Simple Behavioral Analysis (SimBA) as a platform for explainable machine learning in behavioral neuroscience”. In: *Nature Neuroscience* 27.7 (July 2024). Publisher: Nature Publishing Group, pp. 1411–1424. ISSN: 1546-1726. DOI: 10.1038/s41593-024-01649-9. URL: <https://www.nature.com/articles/s41593-024-01649-9> (visited on 01/11/2025).
- [10] Weizhe Hong et al. “Automated measurement of mouse social behaviors using depth sensing, video tracking, and machine learning”. In: *Proceedings of the National Academy of Sciences* 112.38 (Sept. 22, 2015). ISSN: 0027-8424, 1091-6490. DOI: 10.1073/pnas.1515982112. URL: <https://pnas.org/doi/full/10.1073/pnas.1515982112> (visited on 01/10/2025).
- [11] Kyle Hsu, Sergey Levine, and Chelsea Finn. *Unsupervised Learning via Meta-Learning*. Mar. 21, 2019. DOI: 10.48550/arXiv.1810.02334. arXiv: 1810.02334[cs]. URL: <http://arxiv.org/abs/1810.02334> (visited on 01/11/2025).

- [12] Wei-Ning Hsu, Yu Zhang, and James Glass. “Unsupervised Learning of Disentangled and Interpretable Representations from Sequential Data”. In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/hash/0a0a0c8aaa00ade50f74a3f0ca981ed7-Abstract.html (visited on 01/11/2025).
- [13] Francis Huster. « *Tuez-moi, je représente le Christ !* » Déclaration sur CNews. 2024. URL: <https://www.cnews.fr>.
- [14] Mayank Kabra et al. “JAABA: interactive machine learning for automatic annotation of animal behavior”. In: *Nature Methods* 10.1 (Jan. 2013). Publisher: Nature Publishing Group, pp. 64–67. ISSN: 1548-7105. DOI: 10.1038/nmeth.2281. URL: <https://www.nature.com/articles/nmeth.2281> (visited on 01/05/2025).
- [15] Yttri Lab. *B-SOID: Automated Animal Behavior Identification Using Unsupervised Learning*. <https://github.com/YttriLab/B-SOID>. Accessed: 2025-01-13. 2025.
- [16] Ana S Machado et al. “A quantitative framework for whole-body coordination reveals specific deficits in freely walking ataxic mice”. In: *eLife* 4 (Oct. 3, 2015). Ed. by Indira M Raman. Publisher: eLife Sciences Publications, Ltd, e07892. ISSN: 2050-084X. DOI: 10.7554/eLife.07892. URL: <https://doi.org/10.7554/eLife.07892> (visited on 01/05/2025).
- [17] Mackenzie Mathis and collaborators. *DeepLabCut: A Toolbox for Markerless Pose Estimation*. <https://github.com/DeepLabCut/DeepLabCut>. Accessed: 2025-01-13. 2025.
- [18] Ingyu Park et al. “Machine-Learning Based Automatic and Real-time Detection of Mouse Scratching Behaviors”. In: *Experimental Neurobiology* 28.1 (Feb. 2019), pp. 54–61. ISSN: 1226-2560. DOI: 10.5607/en.2019.28.1.54. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6401551/> (visited on 01/10/2025).
- [19] Kasper Peeters. *Introducing Cadabra: a symbolic computer algebra system for field theory problems*. Apr. 3, 2018. DOI: 10.48550/arXiv.hep-th/0701238. arXiv: hep-th/0701238. URL: <http://arxiv.org/abs/hep-th/0701238> (visited on 01/05/2025).
- [20] Cristina Segalin et al. “The Mouse Action Recognition System (MARS) software pipeline for automated analysis of social behaviors in mice”. In: *eLife* 10 (Nov. 30, 2021), e63720. ISSN: 2050-084X. DOI: 10.7554/eLife.63720.
- [21] Ashish Vaswani et al. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.
- [22] Caleb Weinreb et al. *Keypoint-MoSeq: parsing behavior by linking point tracking to pose dynamics*. Pages: 2023.03.16.532307 Section: New Results. Dec. 23, 2023. DOI: 10.1101/2023.03.16.532307. URL: <https://www.biorxiv.org/content/10.1101/2023.03.16.532307v3> (visited on 01/10/2025).
- [23] Alexander B. Wiltschko et al. “Mapping Sub-Second Structure in Mouse Behavior”. In: *Neuron* 88.6 (Dec. 2015), pp. 1121–1135. ISSN: 08966273. DOI: 10.1016/j.neuron.2015.11.031. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0896627315010375> (visited on 01/10/2025).